Proyecto final DataPath con AWS

Por Gonzalo Hernández Hernández

Tecnologías usadas en este proyecto: EMR, Hadoop, HDFS, Hive y Spark



Realizar los siguientes pasos:

Arquitectura de solución loT

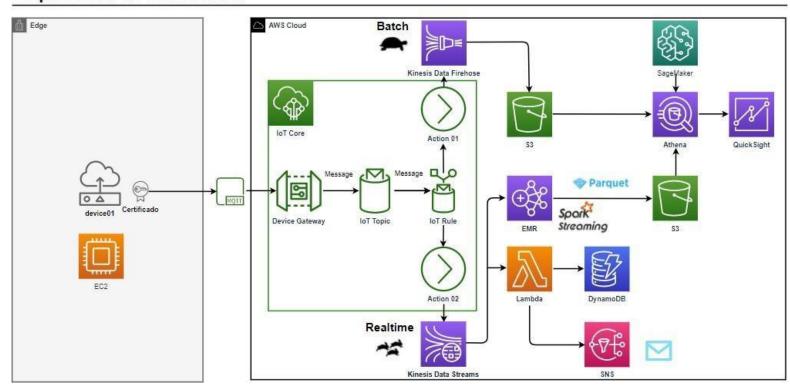


Imagen de la arquitectura propuesta para el proyecto.

a) Entrar a la consola de AWS.

En Cloud9 crear una carpeta y subir los siguientes archivos:

- EMR.yaml
- SendDataSmartFarming.py
- policy-iot-json
- code-spark-streaming

Para crear algunos recursos del proyecto se debe crear el stack de CloudFormation.

Antes de ejecutar agregar el correo a utilizar en la línea 166.

```
rSubscription:
    Type: 'AWS::SNS::Subscription'
    DependsOn: rSnsTopic
    Properties:
        TopicArn: !Ref rSnsTopic
        Endpoint:
        Protocol: email

rFunctionLambda:
    Type: 'AWS::Lambda::Function'
    Properties:
        FunctionName: AlertFarmingRealtime
```

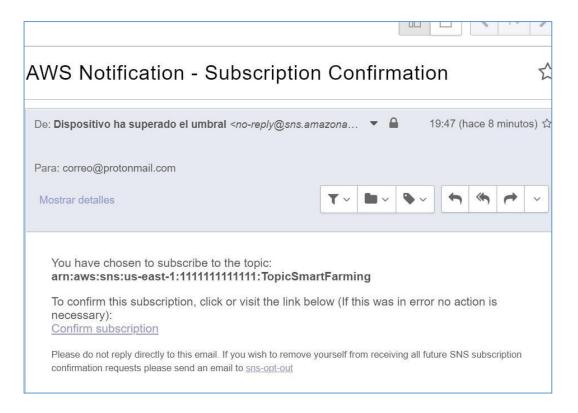
Ejecutar en el AWS CLI, el siguiente comando que creará un conjunto de recursos.

aws cloudformation create-stack --stack-name StackEMR --template-body file://EMR.yaml --capabilities CAPABILITY_NAMED_IAM

El stack de CloudFormation crea los siguientes recursos (tomará menos de minuto aprox):

- Bucket en S3
- Kinesis Data Streams
- Kinesis Data Firehose
- Tabla en DynamoDB
- Tópico en SNS
- Suscriptor en el tópico creado
- Función Lambda
- Regla en IoT con 2 acciones
- b) Confirmar la suscripción al tópico.

Acceder al correo personal y confirmar la suscripción.

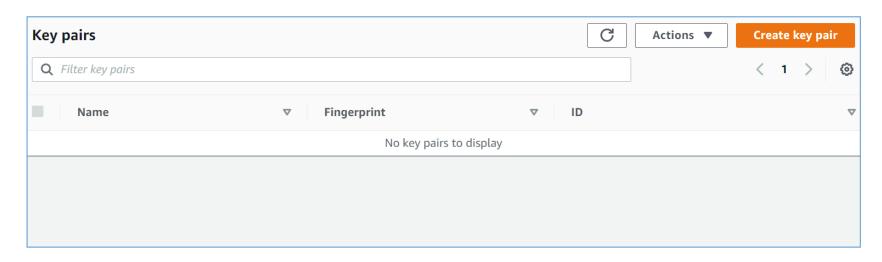


Una vez se le haya dado clic, aparecerá el siguiente mensaje.

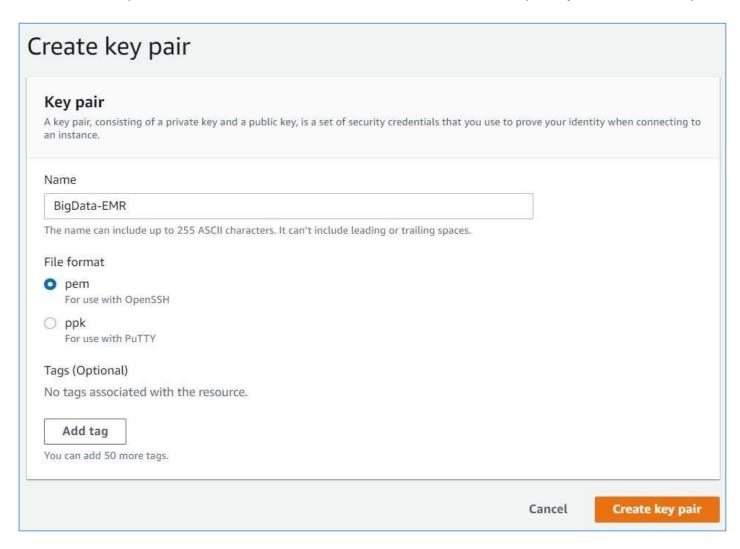


Crear un par de claves.

Ir al servicio de EC2 -> Key pais Clic en Create key pair.



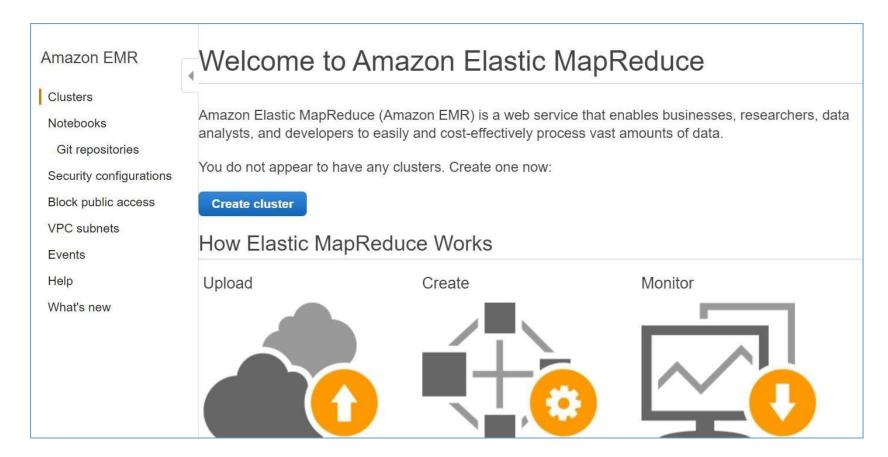
Asignar un nombre al par de claves, seleccionar el formato de archivo pem y clic en Crear par de claves.



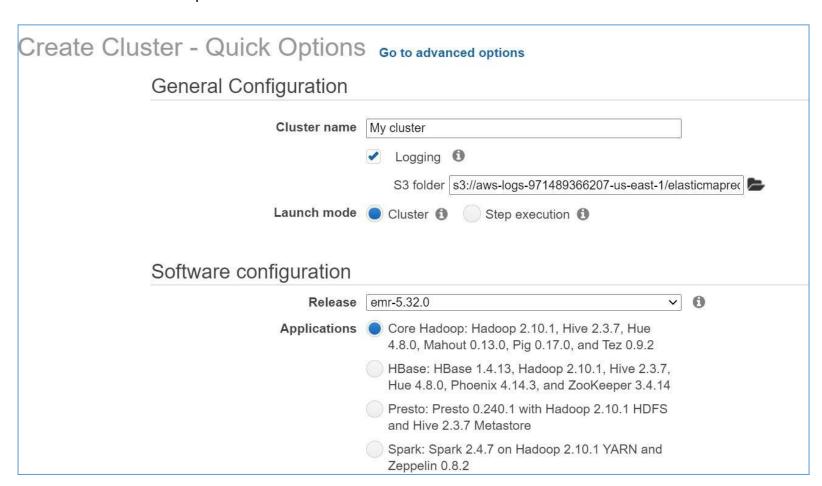
Se descarga el archivo, pem en nuestro pc local (nos servirá para loguearnos al clúster EMR)

c) Crear un clúster en EMR

Clic en Create cluster.

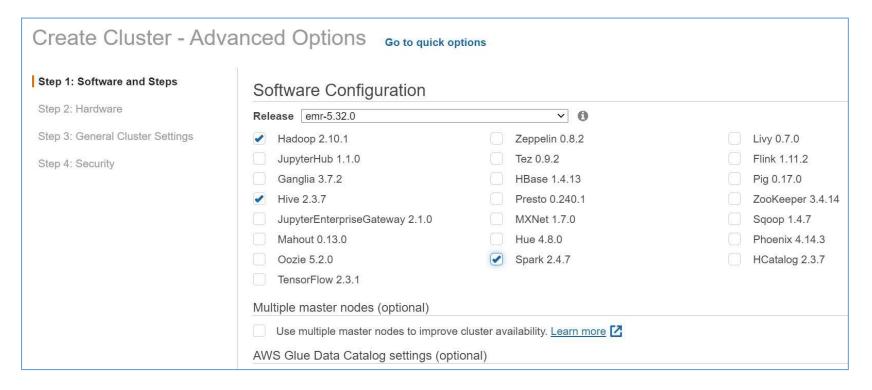


Clic en Go to advanced options.



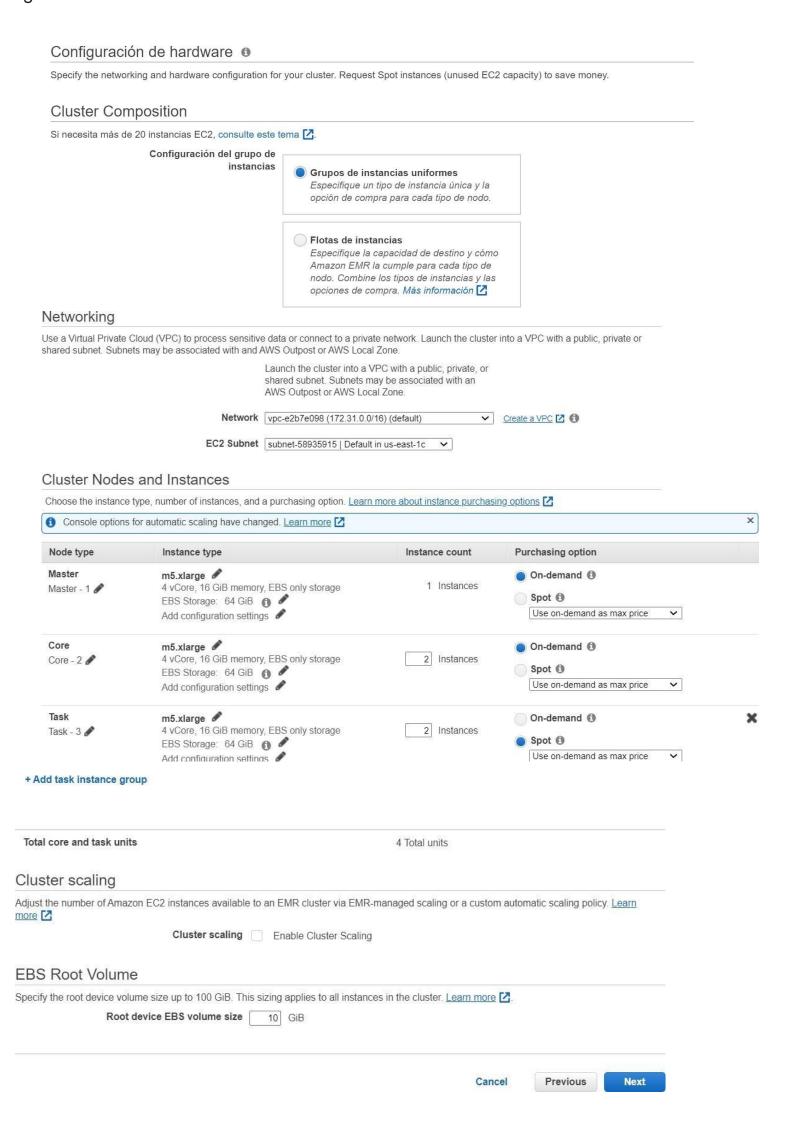
Seleccionar la versión: Emr.5.32.0 Y seleccionar: Hadoop 2.10.0 Hive 2.3.7 Spark 2.4.7

Clic en siguiente.

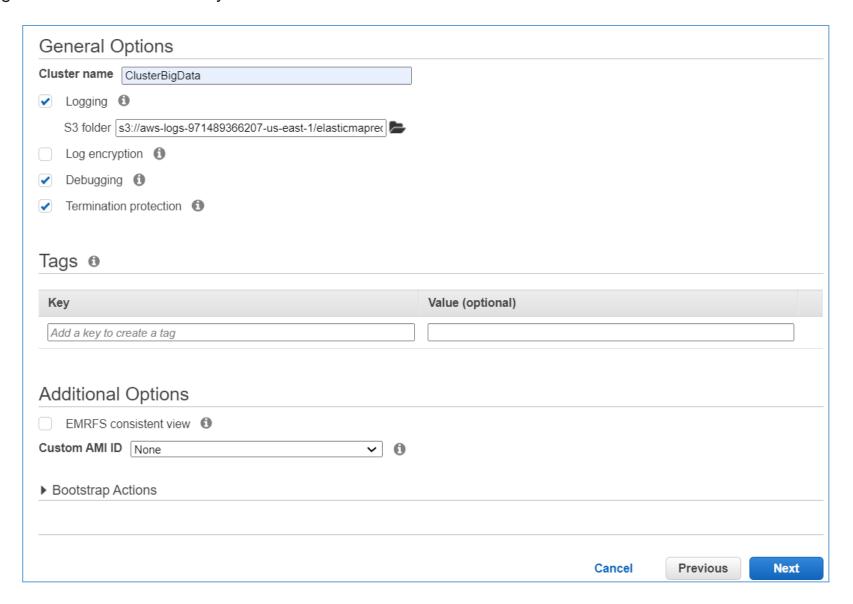


Selecciona la zona de disponibilidad us-east-1a o us-east-1b

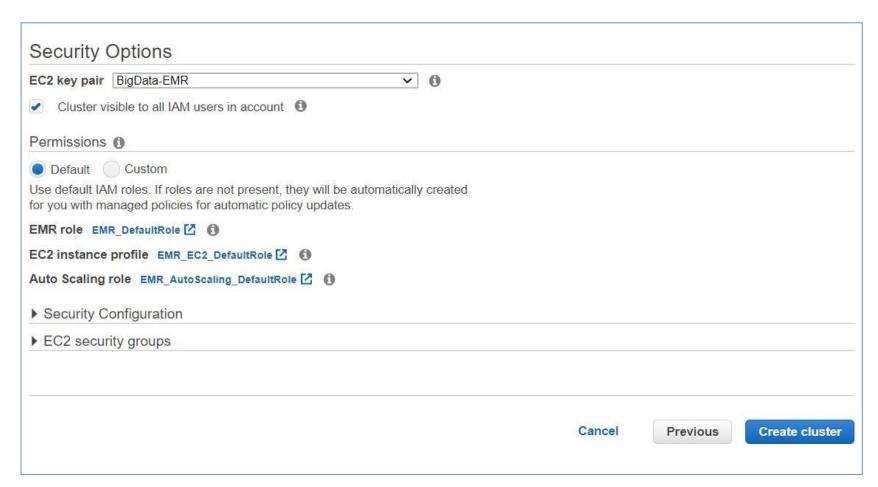
El clúster tendrá: 1 nodo principal, 2 nodos secundarios y 2 nodos de tareas (spot 90% de ahorro) Clic en siguiente.



Asignar un nombre al clúster y clic en Next.



Seleccionar el par de claves que se ha creado y clic en Create cluster.



d) Crear recursos en AWS IoT Core desde el AWS CLI, nos ubicamos en la carpeta 08emr

Ejecutar desde el AWS CLI

aws iot create-thing --thing-name DeviceFarming

Crear certificados y activarlos (pegarlo en una sola línea para que no salga error), copiar el valor del certificateArn.

aws iot create-keys-and-certificate \

- --set-as-active \
- --certificate-pem-outfile certificate.pem.crt \
- --public-key-outfile public.pem.key \
- --private-key-outfile private.pem.key

Crear política

aws iot create-policy --policy-name pol-farming-iot --policy-document file://policy-iot.json

Añadir política al certificado

aws iot attach-policy --target <ARN-NUESTRO-CERTIFICADO> --policy-name pol-farming-iot

Añadir certificado al objeto

aws iot attach-thing-principal --principal <ARN-NUESTRO-CERTIFICADO> --thing-name DeviceFarming

Descargar certificados.

wget https://www.amazontrust.com/repository/AmazonRootCA1.pem

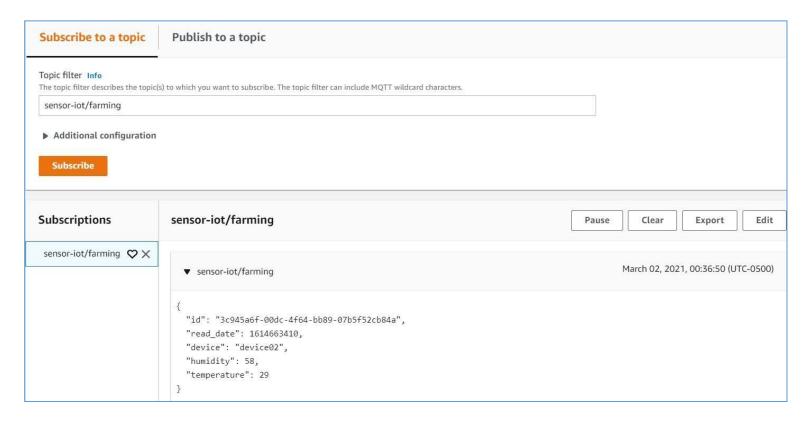
Obtener el valor del endpoint de AWS IoT Core (copiamos el valor del endpoint y remplazarlo en la línea 13 del archivo SendDataSmartFarming.py)

aws iot describe-endpoint --endpoint-type iot:Data-ATS

Ejecutar el archivo SendDataSmartFarming.py para hacer una prueba con el cliente MQTT.

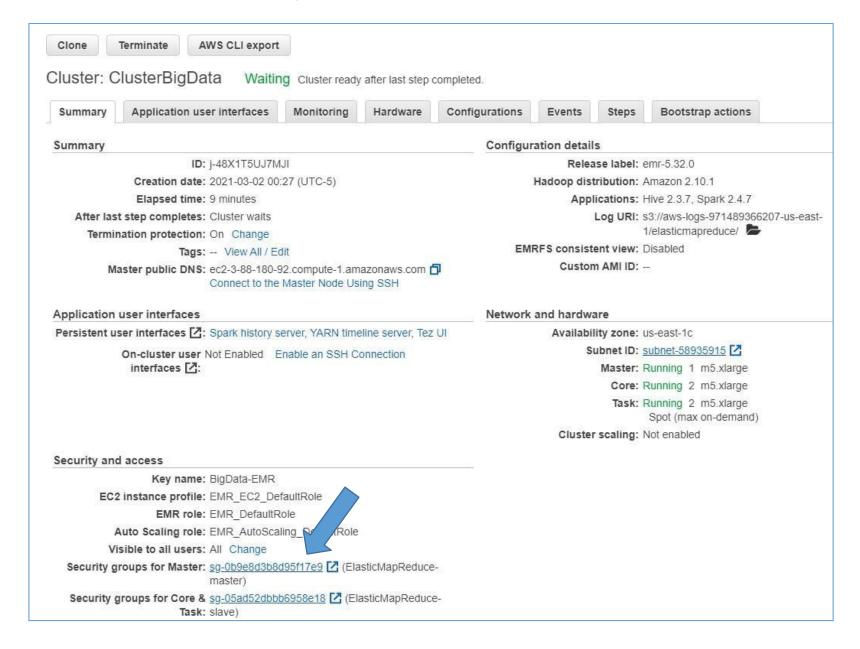
```
bash - "ip-172-31-52 × python3 - "ip-172-31 × bash - "ip-172-31-52 × + ecc-user:~/environment/09EMR $ python3 SendDataSmartFarming.py {
"id": "ae07270e-ca73-471f-9173-95ec01989360", "read_date": 1600062337, "device": "device04", "humidity": 74, "temperature": 15} {
"id": "40a5769f-58ae-419a-ba39-d8aa2bfd64d5", "read_date": 1600062337, "device": "device02", "humidity": 59, "temperature": 29} {
"id": "d0a5769f-58ae-419a-ba39-d8aa2bfd64d5", "read_date": 1600062338, "device": "device04", "humidity": 72, "temperature": 25} {
"id": "26337a52-9f7e-483e-add8-bc17fef06d8e", "read_date": 1600062338, "device": "device02", "humidity": 50, "temperature": 22} {
"id": "105d3397-df05-4af4-9213-23b21e16d351", "read_date": 1600062339, "device": "device04", "humidity": 83, "temperature": 24} {
"id": "20565bff-d1eb-480c-a1bd-f96d53cbdea4", "read_date": 1600062339, "device": "device04", "humidity": 74, "temperature": 28} {
"id": "50e4606-dee5-44ce-905d-f1e0e3b85a51", "read_date": 1600062340, "device": "device04", "humidity": 64, "temperature": 22} {
"id": "3d8ab703-236f-4603-b4eb-933658876b14", "read_date": 1600062340, "device": "device04", "humidity": 51, "temperature": 27} {
"id": "41462050-d44a-40a9-b08c-740bcefe067b", "read_date": 1600062341, "device": "device04", "humidity": 67, "temperature": 16}
```

Verificar en el cliente MQTT que estén llegando los datos. Suscribirse al tópico: sensor-iot/farming

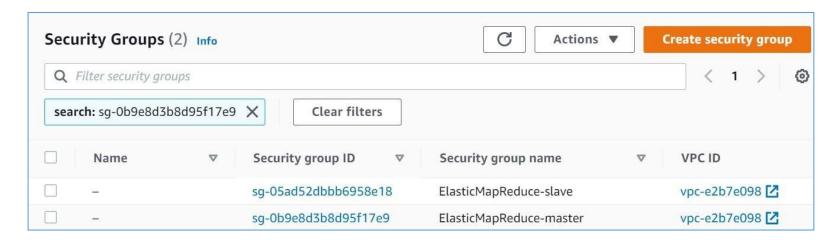


Actualizar reglas de entrada del grupo de seguridad en el EMR.

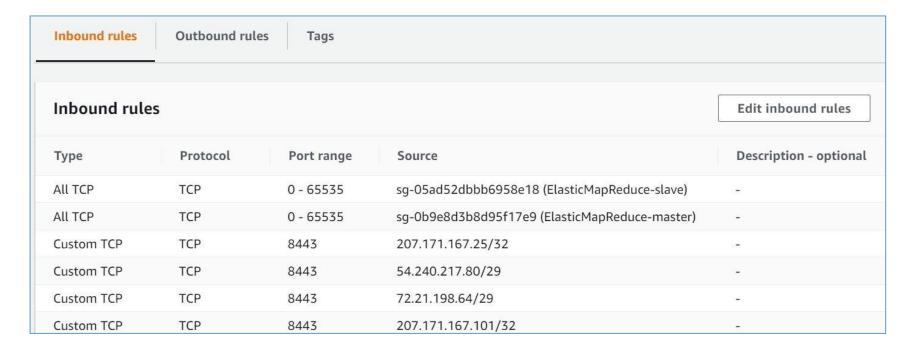
En el EMR, seleccionar el Security group for master.



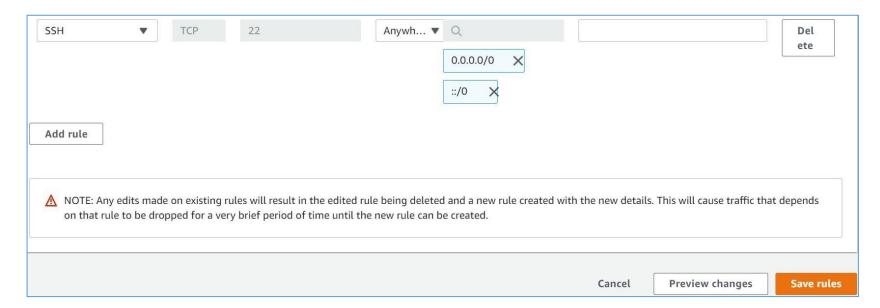
Seleccionar el grupo de seguridad del nodo master.



Clic en Edit inbound rules.

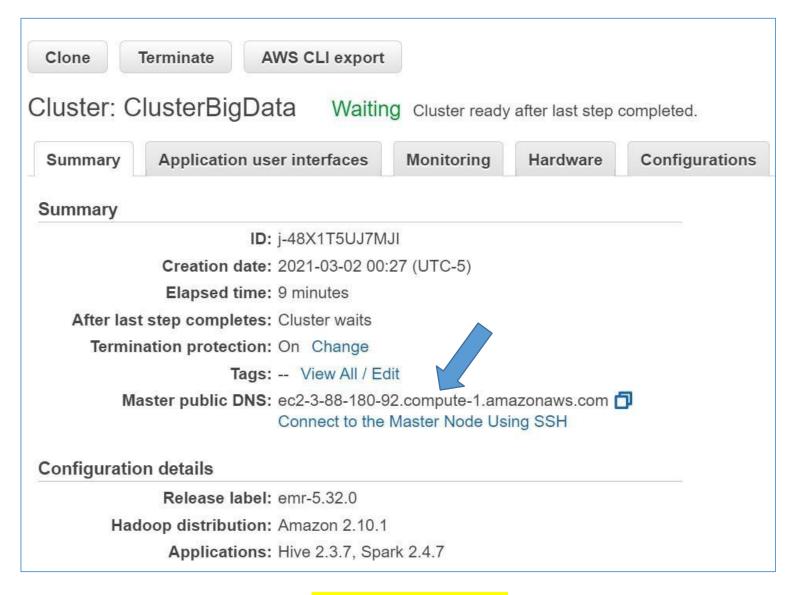


Añadir una nueva regla para el puerto 22, como se muestra, clic en Save rules.



k) Entrar a Cloud9

Subir el archivo pem del par de claves para iniciar sesión en el EMR por SSH. Para iniciar sesión se debe obtener el DNS público principal del EMR.



Ingresar al servicio de IAM, buscar el rol: EMR_EC2_DefaultRole y agregarle la política de Kinesis con la acción ListShards.

Dentro del Cloud9, abrimos un terminal, nos ubicamos en el nivel donde se encuentra el archivo pem y digitamos lo siguiente.

chmod 400 BigData-EMR.pem

ssh -i BigData-EMR.pem hadoop@TU_DNS

```
ec2-user:~/environment/09EMR $ ssh -i BigData-EMR.pem hadoop@ec2-54-209-14-145.compute-1.amazonaws.com
Last login: Fri Jul 17 06:06:44 2020
    https://aws.amazon.com/amazon-linux-2/
18 package(s) needed for security, out of 72 available
Run "sudo yum update" to apply all updates.
EEEEEEEEEEEEEEEEE MMMMMMM
                           E::::E EEEEE M:::::::::M M:::::::::M RR::::R
                                           R::::R
R::::R
                                           R::::R
EE::::EEEEEEEEE::::E M:::::M
                           M:::::M R:::R
                                           R::::R
                            M:::::M RR::::R
                                           R::::R
EEEEEEEEEEEEEEEE MMMMMM
                            MMMMMMM RRRRRRR
                                           RRRRRR
[hadoop@ip-172-31-17-1 ~]$
```

Pasar a la instancia del EMR el código de Spark Streaming

Si se desea poner en producción nuestro código de Spark, se debe compilar y empaquetar el código en un JAR.

Esto se hará usando sbt.

Primeramente se procede a instalarlo ya que no viene en EMR por defecto, así que se debe ejecutar lo siguiente.

```
sudo rm -f /etc/yum.repos.d/bintray-rpm.repo
curl -L https://www.scala-sbt.org/sbt-rpm.repo > sbt-rpm.repo
sudo mv sbt-rpm.repo /etc/yum.repos.d/
sudo yum install sbt -y
```

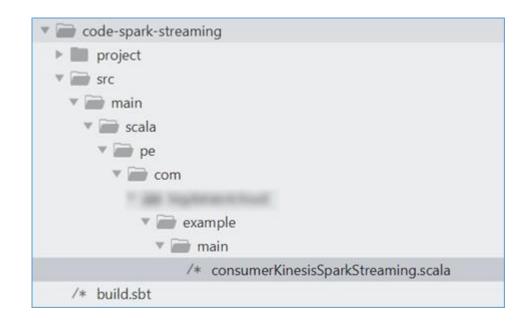
Una vez se haya instalado el sbt, se debe descomprimir el archivo code-spark-streaming.zip

unzip code-spark-streaming.zip

Ya que se haya descomprimido el siguiente paso es posicionarse dentro de la carpeta:

cd code-spark-streaming

sbt assembly



Se debe verificar que se esté ejecutando el código de python:

python3 SendDataSmartFarming.py

```
bash - "ip-172-31-52 ×
                                           python3 - "ip-172-31. ×
 id": "135bc842-aea4-427d-933f-42ce7ebd6e37", "read_date": 1595055909, "device": "device08", "humidity": 72, "temperature": 33
                                                                                                                                                       device08, humidity: 72, temperature: 33}
"device05", "humidity": 81, "temperature": 22}
"device06", "humidity": 82, "temperature": 16}
"device02", "humidity": 90, "temperature": 19}
"device05", "humidity": 84, "temperature": 23}
"device08", "humidity": 80, "temperature": 28}
"device01", "humidity": 55, "temperature": 30}
{"id": "36ed1b59-76d9-470c-967d-b66d7b13ff2e", "read_date": 1595055909, "device": {"id": "fb29d1b7-48a1-4630-811d-165e94fd2248", "read_date": 1595055910, "device": """
("id": "bbadc9aa-cc0a-4053-9508-2265e603818f", "read_date": 1595055910, 
("id": "d8ebd500-415d-4943-abe4-35233a132dad", "read_date": 1595055911,
                                                                                      "read_date": 1595055910,
                                                                                                                                     "device":
{"id": "d9250b48-8ed1-4d8d-ad60-7a7ca3120408", "read_date": 1595055911, 
{"id": "8bf021cd-be4c-489a-9a09-1b8b395143c0", "read_date": 1595055912, 
{"id": "904e76e3-33fa-4508-8ebe-df691ded0226", "read_date": 1595055912,
                                                                                                                                     "device":
                                                                                                                                                        "device01",
                                                                                                                                     "device":
                                                                                                                                                       "device03", "humidity": 59, 
"device01", "humidity": 85,
                                                                                                                                    "device":
                                                                                                                                                                                                            "temperature":
 "id": "6f3eeacf-be9d-4915-9ff7-8606372686a9",
                                                                                                                                     "device":
 "id": "7e0dc306-a4f5-48a4-b636-64c0c0ad3409", "read_date": 1595055913, 
"id": "b9cce9cc-a428-445a-84dd-33d1c6d01e4b", "read_date": 1595055914,
                                                                                                                                                       "device08",
"device05",
                                                                                                                                                                             "humidity": 76,
"humidity": 67,
                                                                                                                                     "device":
                                                                                                                                    "device":
                                                                                                                                                       "device05",
"device04",
"device02",
"device05",
                                                                                                                                                                              "humidity": 54,
"humidity": 68,
 "id": "0aa62038-f4ce-4c95-a7c0-68d076db757d", "read_date": 1595055914, "device": "id": "744f0e5e-13e7-4835-84d5-24a4a662e2b0", "read_date": 1595055915, "device":
                                                                                                                                                                                                           "temperature
  "id": "1a33a90c-e132-4a9f-8490-314509739d8f", "read_date": 1595055915,
"id": "ed88b1c0-d240-4b73-a7ba-a0964322a448", "read_date": 1595055916,
                                                                                                                                                                              "humidity": 86,
"humidity": 72,
                                                                                                                                     "device":
                                                                                                                                                                                                           "temperature":
                                                                                                                                     "device":
  id": "c20ff902-0c49-4390-b40f-0e27f3ba6838", "read_date": 1595055916, "device": "device01", "humidity": 69, "temperature":
```

Ejecutar el siguiente comando en EMR.

Cambiar el nombre del bucket para que se guarde la información que se lea en tiempo real enformato parquet a S3.

El comando debe estar en una sola línea.

spark-submit --class pe.com.proyectoiot.example.main.consumerKinesisSparkStreaming /home/hadoop/code-spark-streaming/target/scala-2.11/kinesis-spark-streaming-assembly-0.1.jar KinesisSparkExample StreamFarming https://kinesis.us-east-1.amazonaws.com s3://smartfarming-xxxxxxxxx/data/input/streaming

```
20/09/14 06:17:15 INFO BlockGenerator: Pushed block input-0-1600064235200
20/09/14 06:17:16 INFO MappedDStream: Slicing from 1600064232000 ms to 1600064236000 ms (aligned to 1600064232000 ms and 1600064236000
20/09/14 06:17:16 INFO JobScheduler: Added jobs for time 1600064236000 ms
20/09/14 06:17:16 INFO JobScheduler: Finished job streaming job 1600064233000 ms.0 from job set of time 1600064233000 ms
20/09/14 06:17:16 INFO JobScheduler: Total delay: 3.008 s for time 1600064233000 ms (execution: 0.814 s)
20/09/14 06:17:16 INFO JobScheduler: Starting job streaming job 1600064234000 ms.0 from job set of time 1600064234000 ms
20/09/14 06:17:16 INFO KinesisBackedBlockRDD: Removing RDD 191 from persistence list
20/09/14 06:17:16 INFO KinesisInputDStream: Removing blocks of RDD KinesisBackedBlockRDD[191] at build at consumerKinesisSparkStreaming
.scala:70 of time 1600064233000 ms
20/09/14 06:17:16 INFO ReceivedBlockTracker: Deleting batches: 1600064226000 ms
20/09/14 06:17:16 INFO InputInfoTracker: remove old batch metadata: 1600064226000 ms
                   id
                                 read_date|
                                                         device
                                                                       humidity|
                                                                                         temperature|
|{"id": "2fd95a78-...|
                                            "device": "devic...|
                                                                 "humidity": 67
                       "read_date": 160...|
                                                                                 "temperature": 28}|
|{"id": "66dcfaf0-...|
                       "read_date": 160...|
                                            "device": "devic...
                                                                                 "temperature": 34}|
                                                                 "humidity": 69
{"id": "1924b951-...| "read_date": 160...|
                                            "device": "devic...
                                                                 "humidity": 85
                                                                                 "temperature": 26}|
                       "read_date": 160...|
                                            "device": "devic...|
[{"id": "59d9361e-...
                                                                 "humidity": 86
                                                                                 "temperature": 26}|
                                            "device": "devic...
{"id": "a9b43f44-...|
                      "read_date": 160...
                                                                 "humidity": 62
                                                                                 "temperature": 25}|
|{"id": "4e266b70-...| "read_date": 160...| "device": "devic...|
                                                                 "humidity": 53
20/09/14 06:17:16 INFO BlockGenerator: Pushed block input-0-1600064236200
```

Una vez terminado el proyecto eliminar los recursos.

Primeramente se debe eliminar el clúster en EMR.

Eliminamos el bucket de S3

aws s3 ls | grep smartfarming | awk {'print "aws s3 rb s3://" \$3 " --force"'} |sh

Y se ejecuta el commando resultante.

Eliminar el stack de CloudFormation.

aws cloudformation delete-stack -- stack-name StackEMR

Eliminar la tabla KinesisSparkExample en DynamoDB

aws dynamodb delete-table --table-name KinesisSparkExample